

你可以把整个项目的数据分成 **三层**，这样就清楚了：

MiniMind 官方通用训练数据

-> 让模型具备基本语言/对话能力

你们自己的金融 DSL 指令数据

-> 让模型学会金融因子/DSL 任务

真实金融行情/因子评测数据

-> 用 FIRE 执行 DSL、计算收益、评估因子效果

1. ModelScope 上的 MiniMind 数据是什么

你提到的这个：

https://www.modelscope.cn/datasets/gongjy/minimind_dataset/files

这是 **MiniMind 官方通用训练数据集**，不是专门的金融数据。

它主要包括这些文件：

数据文件	用途	你们现在是否必须用
pretrain_t2t_mini.jsonl	轻量预训练数据，让模型学习基本语言规律	可选
pretrain_t2t.jsonl	完整预训练数据，更大	不建议现在用
sft_t2t_mini.jsonl	轻量 SFT 数据，让模型学会对话、指令跟随	可选
sft_t2t.jsonl	完整 SFT 数据	不建议现在用
dpo.jsonl	偏好学习 / DPO 数据	暂时不用
rlaif.jsonl	强化学习 / RLAIIF 数据	暂时不用
agent_rl.jsonl	Agent / Tool Use 强化学习数据	暂时不用
agent_rl_math.jsonl	数学工具调用强化学习数据	暂时不用

它们的作用是训练一个通用 MiniMind，而不是训练金融模型。

所以不要误解成：

下载 ModelScope 数据 = 完成金融项目

不是。ModelScope 数据只是 MiniMind 官方为了复现通用模型准备的数据。

2. 你们项目真正需要的数据是什么

按照我们现在的框架，你们最核心需要的是：

金融 DSL 垂直领域 SFT 数据

也就是现在我已经帮你们建的这两个文件：

- `finance_dsl_sft_train.jsonl`
- `finance_dsl_sft_eval.jsonl`

它们长这样：

```
{
  "conversations": [
    {
      "role": "user",
      "content": "请生成一个计算过去20日收盘价均值的因子表达式。"
    },
    {
      "role": "assistant",
      "content": "ts_mean(close, 20)"
    }
  ]
}
```

这类数据是给 `train_full_sft.py` 用的。

作用是让模型学会：

- 解释金融因子；
- 把自然语言转换成 DSL；
- 把 DSL 转换成解释；
- 修正错误 DSL；
- 生成简单因子表达式。

这才是你们项目的主数据。

3. 所谓“金融数据”是不是 FIRE

不完全是。

FIRE 更准确地说是：

金融数据读取 + 因子计算 + 因子评测工具

它不是单纯一个“训练数据集”。

PPT 里提到 FIRE，是因为老师希望你们把 MiniMind 和金融因子场景联系起来：

自然语言问题

-> 模型生成金融 DSL

-> FIRE 执行 DSL / 计算因子

-> FIRE 计算未来收益

-> FIRE 评估 IC、分层收益、稳定性

所以 FIRE 里的“金融数据”通常指：

- 股票价格数据；
- 成交量；
- 估值数据；
- 财务数据；
- 行业分类；
- 未来收益；
- 因子评测结果。

这些数据不是直接拿来喂给 LLM 训练的原始文本，而是用于：

1. 生成金融因子任务；
2. 检查 DSL 是否能执行；
3. 评价生成出来的因子有没有用；
4. 如果做强化学习，可以作为 reward 来源。

4. 对你们小组来说，最低限度要用哪些数据

最稳妥版本：

数据	是否需要	作用
data/finance_dsl_sft_train.jsonl	必须	训练金融 DSL SFT
data/finance_dsl_sft_eval.jsonl	必须	固定测试集
data/finance_dsl_terms.txt	必须	tokenizer 分析、术语表
MiniMind tokenizer	必须	把文本转 token
MiniMind 官方 sft_t2t_mini.jsonl	可选	对比通用 SFT 数据格式
MiniMind 官方 pretrain_t2t_mini.jsonl	可选	从零预训练时才需要
FIRE 真实金融数据	进阶可选	执行 DSL、做因子评测
dpo/rlaif/agent_rl	暂时不用	进阶强化学习

我建议你们当前不要一上来下载全部 ModelScope 数据。文件很大，而且对主线帮助有限。

当前最适合你们的是：

先用我们自己的 finance_dsl_sft_train.jsonl 跑通 SFT

再用 finance_dsl_sft_eval.jsonl 做固定评估

最后如果时间够，再接 FIRE 做真实因子执行/评测

5. 不同数据分别进入哪个训练脚本

训练阶段	数据格式	对应脚本	作用
Pretrain	{"text": "..."} {"conversations": [...]}	train_pretrain.py	学语言规律
SFT	chosen/rejected	train_full_sft.py	学指令回答
DPO	prompt/reward 类数据	train_dpo.py	学偏好
RLAIF / PPO / GRPO	工具调用 + gt	train_ppo.py, train_grpo.py	强化学习
Agent RL		train_agent.py	多轮工具使用

你们现在主线只需要：

SFT 数据 + train_full_sft.py

也就是：

data/finance_dsl_sft_train.jsonl

-> MiniMind SFT

-> 金融 DSL 模型

6. 推荐你们报告里怎么解释数据

可以这样写：

本项目涉及两类数据。第一类是 MiniMind 官方通用训练数据，包括 pretrain、SFT、DPO、RLAIF 和 Agent RL 数据，主要用于复现通用 MiniMind 模型。第二类是本项目构建的金融 DSL 垂直领域数据，采用 MiniMind 的 SFT conversation 格式，用于训练模型完成自然语言到金融因子 DSL 的转换、DSL 解释和错误修正。由于本项目重点是垂直领域 SFT 和优化对比，因此实验主线使用自建金融 DSL SFT 数据，MiniMind 官方数据作为格式参考和可选预训练/通用 SFT 数据。

结论

你现在可以这样理解：

ModelScope MiniMind 数据 = 通用 LLM 训练数据

我们 data/ 里的金融 DSL JSONL = 你们项目主线训练数据

FIRE = 金融数据和因子评测工具，不是必须一开始接入

最稳路线：

先不碰 DPO/RLHF/FIRE

先用金融 DSL SFT 数据跑通 baseline

再做数据优化

最后有余力再用 FIRE 做真实因子执行和评估

参考来源：MiniMind 官方 README 数据说明

<https://github.com/jingyaogong/minimind>

https://www.modelscope.cn/datasets/gongjy/minimind_dataset/files